

西南交通大学
自然语言处理基础课程设计开题报告

基于大模型辅助困难样本增强与轻量蒸馏的中
文短文本情感分析

年 级：_____2023 级_____

学 院：_____计算机与人工智能学院_____

专 业：_____人工智能_____

教学班号：_____1_____

组 号：_____许以诺小组_____

指导教师：_____贾 真_____

二零二六年四月

摘要

情感分析是自然语言处理中的经典任务之一，在商品评论分析、用户反馈理解、网络舆情监测和智能客服等场景中具有明确应用价值。中文短文本情感分类任务边界清晰，公开数据资源较为成熟，基线模型和实验方法也相对稳定，因此适合作为课程设计的研究对象。与此同时，中文短文本中普遍存在否定、转折、程度变化、隐含主观表达和网络化口语等复杂语言现象，模型在这些样本上的误判问题仍然比较突出。课题将这一类文本作为重点关注对象，希望在已有基线的基础上，进一步提升模型对复杂表达的适应能力和分类稳定性。

本课题以 ChnSentiCorp 作为主数据集，计划构建 TextCNN、BiLSTM、BERT 和 MacBERT 等基线模型，先形成清晰的性能比较体系，再引入大模型 API 参与困难样本构造、标签一致性校验、样本质量评分和教师信号生成，进一步结合蒸馏训练提升轻量模型在复杂文本上的表现。整个研究围绕数据准备、基线训练、困难样本增强、质量控制、蒸馏训练和结果分析几个环节展开，目标是在保证课题可实现性的前提下，形成一套较完整的中文短文本情感分析改进方案。

课题中的大模型不会直接承担最终分类任务。API 的作用主要落在训练支持环节，包括样本生成、样本复核和教师信号提供，使项目的工作重点更清楚地落在自然语言处理任务建模、实验设计和方法分析上。本课题希望在总体测试集和困难样本子集上都取得较稳定的结果，并通过对比实验与误差分析说明各模块的实际作用。

关键词：情感分析；中文短文本分类；大模型 API；困难样本增强；知识蒸馏

Abstract

Sentiment analysis is one of the classic tasks in natural language processing and has clear practical value in scenarios such as product review analysis, user feedback understanding, online public opinion monitoring, and intelligent customer service. Chinese short-text sentiment classification has clear task boundaries, relatively mature public datasets, and fairly stable baseline models and experimental settings, making it a suitable topic for a course project. At the same time, Chinese short texts often contain complex linguistic phenomena such as negation, contrast, degree variation, implicit subjective expressions, and Internet colloquialisms, and model misclassification on such samples remains a prominent issue. This project therefore pays special attention to these challenging cases, with the aim of further improving model adaptability and robustness on complex expressions based on existing baselines.

This project uses ChnSentiCorp as the primary dataset and plans to build baseline models including TextCNN, BiLSTM, BERT, and MacBERT. A clear performance comparison framework will first be established, after which LLM APIs will be introduced to support hard-sample construction, label consistency verification, sample quality assessment, and the generation of teacher signals for distillation. On this basis, distillation training will be incorporated to improve the performance of lightweight models on complex texts. The overall study will cover several key stages, including data preparation, baseline training, hard-sample augmentation, quality control, distillation training, and result analysis. The goal is to develop a relatively complete improvement framework for Chinese short-text sentiment analysis while ensuring the feasibility of the project.

Large language models will not serve as the final classifiers in this project. Instead, the APIs will mainly be used in the training support stage, including sample generation, sample review, and the provision of teacher signals, so that the main focus of the project remains on NLP task modeling, experimental design, and methodological analysis. The project aims to achieve stable performance on both the overall test set and the hard-sample subset, and to clarify the actual contribution of each module through comparative experiments and error analysis.

Key words: Sentiment Analysis; Chinese Short-Text Classification; LLM API; Hard-Sample Augmentation; Knowledge Distillation

目 录

第 1 章 课题的目的及意义	7
1.1 关键信息	7
1.2 报告所做工作及路线	8
1.3 报告章节安排	8
第 2 章 国内外研究现状	10
2.1 国内外文献综述	10
2.2 课题最相关论文的总结	11
2.3 参考文献	13
第 3 章 设计任务与要求	15
3.1 课题目标	15
3.2 解决的 NLP 任务	15
第 4 章 拟采取的技术路线与试验方案	17
4.1 实验数据	17
4.2 拟使用的方法与技术	17
4.2.1 总体方法框架	17
4.2.2 基线模型与主方法选择	18
4.2.3 已发布方法的变体设计	18
4.2.4 困难样本增强策略	19
4.2.5 轻量蒸馏方案	19
4.2.6 自行实现与下载使用部分	20
4.2.7 原创内容	20
4.2.8 结果评价指标	20
第 5 章 项目实施安排	22
5.1 预期成果	22
5.2 设计进度安排	22
5.3 小组成员和分工	23

图目录

图 2-1	BERT 模型预训练与微调示例	10
图 2-2	情感分析任务针对性蒸馏示意图	11
图 2-3	少样本学习在不同文本分析任务中的性能提升对比	12
图 2-4	MacBERT 实验结果示例	13
图 3-1	任务流程主图	15
图 4-1	困难样本数据挖掘示意图	19

表目录

表 5-1	设计进度安排	23
表 5-2	小组成员分工	24

第1章 课题的目的及意义

情感分析长期以来都是自然语言处理中的基础任务，在商品评论分析、用户反馈理解、在线服务评价和网络舆情监测等场景中都具有现实意义。其中，中文短文本情感分析有很好的训练价值，其任务定义清楚，输入输出边界明确，公开数据集比较成熟，模型路线也比较稳定，能够把数据处理、模型训练、实验比较和结果分析几部分内容自然地串联起来。

中文短文本情感分类真正值得研究的地方，并不只在于模型能否分出正向和负向，而在于模型面对复杂表达时是否还能保持稳定。很多文本并不会直接使用明显的情感词，而是通过否定、转折、程度副词变化、隐含评价和口语化方式表达态度。模型在这些样本上的误判，往往比普通样本上的误差更能说明问题。本课题把困难样本作为关注重点，目的就是让模型在训练阶段接触更多复杂语言现象，使其学到更接近真实场景的判断方式。

大模型的发展为这类研究提供了新的训练支持手段，本课题中，API 的任务集中在困难样本生成、标签一致性复核、样本质量筛选和教师信号构造几个环节，使工作重点能集中保留在数据组织、模型训练和实验分析上，也更符合课程设计对方法贡献和工作量的要求。

本课题的意义可概括为以下三个方面：

- **任务层面的意义。**中文短文本情感分析具有明确的研究对象和稳定的数据基础，适合开展系统实验；
- **方法层面的意义。**项目探索的是如何把大模型能力合理地用于训练流程，而不是把 API 当作替代实验的工具；
- **实践层面的意义。**最终承担情感分类任务的仍是本地可训练、可比较、可部署的模型，这使本课题更具工程合理性，也更适合本科课程设计的实现条件。

1.1 关键信息

- 题目：基于大模型辅助困难样本增强与轻量蒸馏的中文短文本情感分析
- 成员：
 - 成员 1：许以诺 2023112349
 - 成员 2：陈康 2023112364
 - 成员 3：侯睿元 2023112355
 - 成员 4：谭逸朗 2023110392
- 是否和其他课程共享课题： 否
- 课题简单描述：本课题围绕中文短文本情感分析展开，研究重点为复杂语言现象下模型分类稳定性的提升。中文情感分类任务虽然已经具备较成熟的公开数据和较强的预训练模型基线，但在否定、转折、程度变化、隐含主观表达和网络口语等复杂文本上，模型仍然容易出现误判。课题计划以 ChnSentiCorp 作为主数据集，先构建 TextCNN、BiLSTM、BERT、MacBERT 等基线模型，再引入大模型 API 参与困难样本生成、标签一致性校验、样本质量评分和教师信号构造，进一步通过蒸馏训练提升轻量模型的泛化能力与鲁棒性。整个项目希望形成一套从数据准备、样本增强、模型训练到结果分析都较为完整的实验流程，使课题具有明确的自

然语言处理任务边界，也具备可落实的方法创新点。

1.2 报告所做工作及路线

本课题围绕**基于大模型辅助困难样本增强与轻量蒸馏的中文短文本情感分析**展开。课题的核心目标是在一个相对成熟、容易落地的情感分析任务上，探索如何借助大模型的语义理解能力提升传统情感分类模型在复杂样本上的表现。本文的工作思路可概括为基线复现 → 误差分析 → 困难样本增强 → 知识蒸馏 → 对比评估五个阶段。

本课题选择中文短文本情感分类作为研究对象，主要基于三个方面考虑：

- 本任务属于自然语言处理中的典型文本分类任务，输入输出清晰、实验边界明确，容易与课程中所学的词表示、序列建模、预训练语言模型等知识形成呼应；
- 公开中文数据集和基线模型相对丰富，便于在有限时间内完成较完整的实验设计；
- 近年来关于情感分析与大模型结合的研究已逐步从直接用大模型完成分类转向利用大模型提升紧凑模型能力，这为本科课程设计提供了一个既有创新点又不至于过度复杂的切入方向。

方法设计层面，本课题重点考察两类可操作的方法创新。其一是困难样本增强，即让大模型在保持原始情感标签不变的前提下，对训练样本进行可控改写，从而生成更具挑战性的训练数据。第二类是轻量蒸馏，即让教师模型向学生模型提供更加平滑、更具结构性的监督信号，帮助学生模型在较小参数量下学习更稳定的决策边界。同时，本课题强调循序渐进的比较过程，而不是一开始就堆叠复杂模块。具体而言，在已建立好 TextCNN 和 BiLSTM 等基础模型的前提下，再进一步建立 BERT 和 MacBERT 等较强基线，通过统一数据预处理和评价指标获得可比结果。同时可引入大模型增强模块，在同一训练集和测试集划分下重新训练模型并比较差异。上述比较完成之后，可逐步增加蒸馏实验和消融实验，以分析困难样本增强和蒸馏策略分别带来的效果。

1.3 报告章节安排

本报告共分为 5 章：

第 1 章为课题的目的及意义，主要说明课题的基本信息、研究背景与选题意义，并对本报告的整体思路和章节安排作总体介绍；

第 2 章为国内外研究现状。本章主要对中文短文本情感分析及相关方法的国内外研究进展进行综述，在此基础上总结本课题最相关论文的研究背景、主要贡献、存在不足及其对本课题的启发，并整理本章所涉及的参考文献；

第 3 章为设计任务与要求，重点说明本课题的研究目标以及需要解决的自然语言处理任务，对课题拟完成的主要内容、基本要求和研究边界进行明确界定；

第 4 章为拟采取的技术路线与试验方案。本章首先介绍实验数据来源与预处理思路，随后说明本课题拟采用的方法与技术，包括总体方法框架、基线模型与主方法选择、已发布方法的变体设计、困难样本增强策略、轻量蒸馏方案、自行实现与下载使用部分、原创内容以及结果评价指标等内容，是本报告的核心部分；

第 5 章为项目实施安排，主要说明课题的预期成果、设计进度安排以及小组成员和分工，

为后续课题实施和结题答辩提供计划依据；

本报告当前处于开题与方案设计阶段，故正文内容以研究设计、方法规划和实施安排为主，实验部分主要给出可执行的试验思路与分析框架，后续在课题推进过程中，将根据实际实验情况对结果、图表和分析内容做进一步补充和完善。

第 2 章 国内外研究现状

2.1 国内外文献综述

情感分析的发展路线较为清晰，早期研究主要依赖情感词典、人工规则和传统机器学习方法，随着深度学习模型逐渐成为主流，TextCNN、BiLSTM 等模型在文本分类任务中积累了大量应用经验。再往后，预训练语言模型进入主流阶段，BERT、RoBERTa 以及面向中文的 MacBERT 等模型显著提升了情感分析任务的整体表现。对中文任务而言，预训练模型带来的提升尤其明显，这说明情感分析已经具备较强基线，但也意味着后续研究不能只停留在再训练一个分类器的层面。




图 2-1 BERT 模型预训练与微调示例

国外近年的研究重点，越来越关注大语言模型在情感分析中的真实能力和合理使用方式。如 Findings of NAACL 2024 的 Sentiment Analysis in the Era of Large Language Models: A Reality Check 对多类情感分析任务和多个数据集进行了系统评估。研究表明，大模型在部分简单任务和少样本场景下表现较强，但在更复杂、更细粒度的情感任务中，并不总能稳定优于专门训练的小模型。上述结论说明情感分析在大模型时代仍然有继续研究的必要，下游模型训练和任务建模仍然有价值。

另一类国外的情感分析研究则把重心放在知识迁移和模型的高效化上。EMNLP 2025 的 Targeted Distillation for Sentiment Analysis 就是这一方向的代表性工作，该文围绕情感分析任务中的教师—学生模型关系展开研究，希望通过蒸馏训练让更轻量的学生模型吸收教师模型的知识，从而兼顾性能与部署效率。上述思路对本课题有直接启发，因为本课题同样希望在中文情感分析任务上提升轻量模型在复杂样本中的表现。

中文研究方面，情感分析一直是自然语言处理中的重要方向。围绕评论文本、微博文本、用户反馈和社区语料，国内已经积累了较多研究成果。随着中文预训练模型的发展，MacBERT 等模型在中文单句分类任务上已经能取得较高表现，即中文短文本情感分析本身已经不属于低门槛、低要求的简单任务，课题需将精力放在更有解释力的改进方向上。将困难样本增强、标签一致性复核和蒸馏训练结合起来，正是为了把研究重心落在模型最容易失效的地方，而不是重复已有强基线结论。

综合现有研究可得到以下两个判断：

- 中文短文本情感分析任务边界清晰、数据成熟、研究问题明确；
- 大模型在这个任务中的价值，更适合体现在训练支持和知识迁移层面，而不只是作为直接分类器使用。

2.2 课题最相关论文的总结

本课题以 Targeted Distillation for Sentiment Analysis 为研究的主论文。论文作者为 Yice Zhang、Guangyu Xie、Jingjie Lin、Jianzhu Bao、Qianlong Wang、Xi Zeng、Ruifeng Xu，发表于 Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing(EMNLP 2025)。论文链接为 <https://aclanthology.org/2025.emnlp-main.1127/>。上述论文来自情感分析任务中的一个现实问题，即主要关注在情感分析任务中如何将更强模型的知识有效迁移给更紧凑、更易部署的学生模型。随着大语言模型能力的不断增强，情感分析系统在理论上可借助更强的教师模型以获得更丰富的语义知识，并在语义理解和上下文建模方面获得了新的提升空间。但在实际场景中，成本、推理速度和部署条件仍然决定了轻量模型的重要性，真正需要部署的往往仍然是推理速度更快、资源消耗更低的学生模型。论文正是在这一背景下展开研究，如何让学生模型在不显著增加复杂度的前提下，吸收教师模型在情绪判断、上下文理解和类别边界建模方面的优势，是论文试图解决的核心问题。上述论文在摘要和引言中明确指出，其研究目标是面向情感分析任务开展针对性蒸馏，并将蒸馏目标区分为知识与对齐两个层面，这一表述见原论文第 1-2 页。

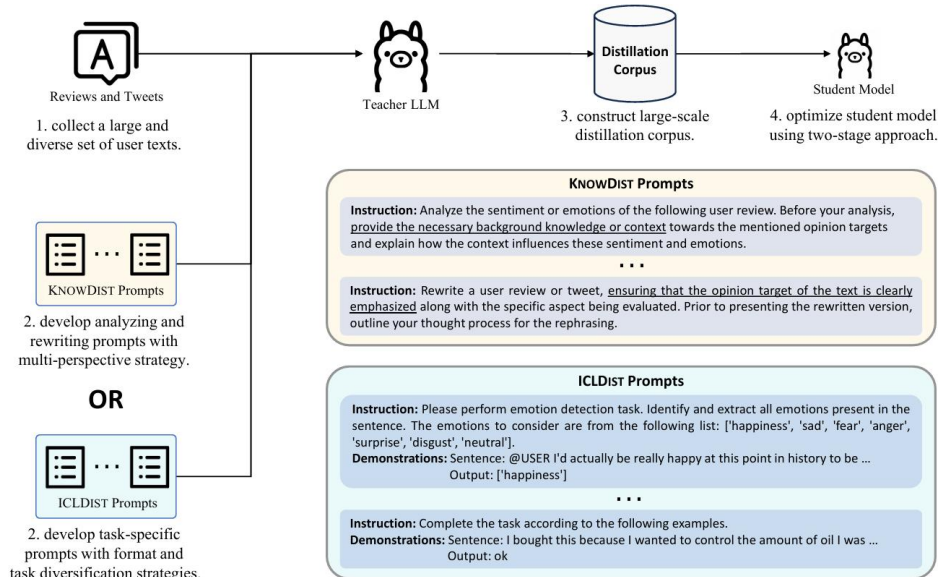


图 2-2 情感分析任务针对性蒸馏示意图

论文作者围绕情感分析任务提出了较有针对性的蒸馏思路，将教师模型的知识迁移过程组织得更清晰，同时构建了覆盖多个数据集的评测基准，使不同蒸馏策略和不同模型之间的比较更有系统性。论文给出的实验结论说明，经过蒸馏训练后，紧凑模型在多类情感分析任务中仍然可以保持较强表现，这一结论对于本课题具有很强的启发意义，本课题同样希望在保持模型可训练、可部署的前提下，提高其对复杂中文情感表达的处理能力。论文的主要贡献可概括为以下三点：

- 论文提出了一个两阶段蒸馏框架，即将蒸馏过程拆分为 knowledge-driven distillation (KNOWDIST)和 in-context learning distillation(ICLDIST)两阶段，使蒸馏策略更有针对性，这一内容位于原论文第 1-2 页；

- 论文构建了一个覆盖 3 类任务、12 个数据集的情感分析基准 SENTIBENCH，为不同模型和不同蒸馏策略提供了统一的实验平台，这一内容位于原论文第 1-4 页；

- 论文实验结果表明，该方法能够显著提升紧凑模型在多类情感分析任务上的表现，并使蒸馏后的模型在未见任务上仍保持较强竞争力，这部分核心结论见原论文第 1-2 页及后续实验部分。

这篇论文并不是没有局限，其方法体系相对完整，实验规模较大，若在本课题中完全按原样展开，工作量和实现成本都会明显上升。与此同时，论文更关注一般意义上的情感分析蒸馏问题，对中文短文本中常见的否定、转折、程度变化、隐含主观表达和口语扰动等现象并没有展开专门的样本级处理设计。这意味着它更适合作为本课题的方法依据，而不适合作为需要逐项照搬的实现模板。本课题选择这篇论文作为最相关主论文，因为其当前课题的研究目标联系最为紧密。本课题并不满足于训练一个普通中文情感分类模型，而是希望在复杂样本上进一步提升轻量模型的稳定性，这与论文所强调的知识迁移思路高度一致。同时，论文提供了较明确的蒸馏主线，而本课题则在此基础上进一步加入困难样本增强、标签一致性校验和样本质量控制，使方法更贴近中文短文本情感分析的实际需求，也更符合本课题对于有方法贡献的要求。大模型可被使用，但必须体现基于 API 的实际贡献，不能只是依靠 prompt 直接生成文本，这也是本课题没有把大模型当作最终分类器，而是把它放进训练流程内部的重要原因。本课题正是在这篇论文蒸馏思路的基础上，将大模型 API 进一步用于困难样本生成、标签一致性校验和样本质量控制，从而形成符合课程要求的研究方案。

除论文所聚焦的情感分析问题外，上述论文还与多个自然语言处理方向密切相关。1° 语言表示学习方面：蒸馏训练本质上涉及教师模型语义知识向学生模型的迁移；2° 文本分类方面：情感分析本身就是典型的文本分类任务；3° 模型压缩和高效推理方面：论文强调的是在保持较低部署成本的前提下提升模型性能；4° 知识迁移、指令学习和跨任务泛化方面：论文中 ICLDIST 阶段已经涉及对模型任务适应能力的学习。就方法思路而言，这种框架同样可以扩展到立场检测、主观性识别、评论质量评估等任务，因此其对于本课题并不仅仅是一篇可参考的论文，而是能够提供方法主线和实验组织依据的关键文献。




图 2-3 少样本学习在不同文本分析任务中的性能提升对比

为了让选题依据更完整，本课题还参考了两篇辅助性文献，用于补足研究背景和中文基线依据。Sentiment Analysis in the Era of Large Language Models: A Reality Check (Findings of NAACL 2024)系统评估了大语言模型在 13 类任务、26 个数据集 上的表现，指出大模型在简单任务上已经表现较好，但在复杂情感任务中仍存在能力边界，这一结论见原论文第 1-2 页 和 第 9 页 。 另 一 篇 文 献 Revisiting Pre-Trained Models for Chinese Natural Language Processing(Findings of EMNLP 2020)则为中文预训练模型基线的选择提供了直接依据，使本课题采用 MacBERT 作为中文强基线更具合理性。论文在单句分类实验中使用了 ChnSentiCorp，并报告了较高的测试结果，其中 MacBERT-base 和 RoBERTa-wwm-ext 在 ChnSentiCorp 上达到 95.6，MacBERT-large 在相关实验设置中达到 95.9，对应内容见原论文第 7-9 页。该结果说明中文情感分类任务本身已有较强基线，故本课题更适合把创新点放在困难样本增强、样本质量控制和蒸馏训练上，而不是额外构造复杂新模型。通过上述三类文献的结合，本课题的研究背景、方法主线和中文场景落地依据就形成了比较清楚的对应关系。

	CMRC 2018		DRCD		CJRC		CSC	THUC	XNLI	LC	BQ	AVG
	EM	F1	EM	F1	EM	F1	ACC	ACC	ACC	ACC	ACC	
MacBERT-large	74.8	90.7	91.7	95.6	62.9	82.5	95.9	97.9	81.3	87.6	85.6	87.18
SOP → NSP	74.5	90.6	91.5	95.5	62.4	82.3	96.0	97.8	81.2	87.4	85.2	87.00
w/o SOP	74.4	90.6	91.0	95.4	62.2	82.1	95.8	97.8	81.1	87.4	85.2	86.89
w/o Mac	74.2	90.1	91.2	95.4	62.2	82.3	95.7	97.8	81.2	87.4	85.3	86.88
w/o NM	74.0	89.8	90.9	95.1	62.1	82.0	95.9	97.9	81.3	87.5	85.6	86.89
RoBERTa-large	74.2	90.6	89.6	94.5	62.4	82.2	95.8	97.8	81.2	87.0	85.8	86.79

图 2-4 MacBERT 实验结果示例

基于以上文献分析，本课题最终确定为基于大模型辅助困难样本增强与轻量蒸馏的中文短文本情感分析。此选题既属于标准 NLP 任务，输入输出边界清楚，又能体现出围绕大模型 API 展开的实际方法贡献，极其适合作为本次课程设计开题报告中的核心研究方向。

2.3 参考文献

- [1] Zhang, Yice, Xie, Guangyu, Lin, Jingjie, Bao, Jianzhu, Wang, Qianlong, Zeng, Xi, and Xu, Ruifeng. 2025. Targeted Distillation for Sentiment Analysis. In Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, Suzhou, China.
- [2] Zhang, Wenxuan, Deng, Yue, Liu, Bing, Pan, Sinno Jialin, and Bing, Lidong. 2024. Sentiment Analysis in the Era of Large Language Models: A Reality Check. Findings of the Association for Computational Linguistics: NAACL 2024.
- [3] Cui, Yiming, Che, Wanxiang, Liu, Ting, Qin, Bing, Wang, Shijin, and Hu, Guoping. 2020. Revisiting Pre-Trained Models for Chinese Natural Language Processing. Findings of the Association for Computational Linguistics: EMNLP 2020.
- [4] ChnSentiCorp Dataset. Hugging Face dataset page.
- [5] Kim Y. Convolutional neural networks for sentence classification[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Doha: Association for Computational Linguistics, 2014: 1746-1751.

- [6] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [7] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Minneapolis: Association for Computational Linguistics, 2019: 4171-4186.
- [8] Cui Y, Che W, Liu T, Qin B, Wang S, Hu G. Revisiting pre-trained models for Chinese natural language processing[C]//Findings of the Association for Computational Linguistics: EMNLP 2020. Online: Association for Computational Linguistics, 2020: 657-668.
- [9] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems 33. Red Hook, NY: Curran Associates, Inc., 2020: 1877-1901.
- [10] Zhang W, Deng Y, Liu B, Pan S J, Bing L. Sentiment analysis in the era of large language models: A reality check[C]//Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City: Association for Computational Linguistics, 2024: 3881-3906.
- [11] Zhang Y, Xie G, Lin J, Bao J, Wang Q, Zeng X, Xu R. Targeted distillation for sentiment analysis[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou: Association for Computational Linguistics, 2025.
- [12] Xu L, Hu H, Zhang X, et al. CLUE: A Chinese language understanding evaluation benchmark[EB/OL]. [2026-04-11]. <https://www.cluebenchmarks.com/>.
- [13] ChnSentiCorp dataset[DB/OL]. [2026-04-11]. <https://huggingface.co/datasets/lansinute/ChnSentiCorp>.

第3章 设计任务与要求

3.1 课题目标

本课题拟在中文短文本情感分析任务上完成一个具有完整实验链条的小型研究项目。研究将以公开数据集为基础，系统比较 TextCNN、BiLSTM、BERT 和 MacBERT 等模型在中文短文本情感分类任务上的表现，建立清楚、可靠的基线结果，并在此基础上通过困难样本增强与轻量蒸馏进一步提升模型对复杂语言现象的适应能力。本课题关注的不只是总体指标变化，还包括模型在否定、转折、程度变化、隐含主观表达和网络口语等困难样本上的鲁棒性表现，这也是后续实验分析的重点。

上述目标具有较明确的重要性和挑战性，中文短文本情感分析虽然属于较成熟的自然语言处理任务，但在真实文本中，情绪表达方式往往并不直接，模型很容易受到句式结构变化和隐含语义的影响而出现误判。如何在保持实验可实现性和模型可部署性的前提下，提高模型对复杂表达的识别能力，是本课题希望解决的核心问题。对于课程设计而言，这一目标既能够体现自然语言处理任务建模、模型比较和实验分析的完整过程，也具有较好的研究价值和实现可行性。本课题与主论文之间具有明确联系。主论文提供的是情感分析中的蒸馏思路和教师—学生知识迁移逻辑，本课题则进一步结合中文短文本情感分析任务，把训练支持延伸到困难样本增强、标签一致性复核和样本质量筛选等环节。这样处理之后，项目既保留了主论文的方法价值，也形成了更适合课程设计场景的实验路线。




图 3-1 任务流程主图

3.2 解决的 NLP 任务

本课题面向的任务是中文短文本情感分析，具体的研究对象主要是商品评论、用户反馈以及其他带有主观态度的简短文本，目标为判断文本整体表达的是正向情绪还是负向情绪。与长文本理解或复杂推理任务相比，这一任务的输入输出关系更清楚，数据获取更方便，但在真实文本中并不意味着判断过程就很简单。很多评论并不会直接使用明显的情感词，而是通过否定、转折、程度副词变化、含蓄表达或口语化形式传递态度，因此模型是否能够抓住真正决定情感倾向的线索，是本课题关注的重点。从任务形式来看，输入是一条中文短文本，输出是该文本对应的情感极性标签。当前阶段采用二分类设定，将标签划分为正向和负

向。例如，输入“这家店环境不错，但是服务态度让人失望”，模型应当输出“负向”；输入“物流很快，包装也很仔细，整体体验很好”，模型应当输出“正向”。这样的输入输出关系为后续实验提供了稳定基础，也便于在同一任务框架下比较不同模型和不同训练策略的效果。

围绕这一任务，课题将把文本输入到 TextCNN、BiLSTM、BERT 和 MacBERT 等神经网络模型中，由模型完成文本表示学习和情感判别。对于轻量模型来说，输入经过编码后形成序列表示，模型从中提取局部模式或上下文依赖信息，再输出属于正向或负向的概率分布；对于预训练语言模型来说，文本经过 tokenizer 编码后进入模型，由上下文表示直接支持分类决策，最终给出情感类别预测。无论采用哪一类模型，输入始终是中文短文本，输出始终是情感极性标签，这使得原始基线训练、困难样本增强训练和蒸馏训练能够放在统一框架下进行比较。本课题之所以把中文短文本情感分析作为核心任务，还因为它既具有明确的课程实现价值，也具有足够的研究空间。公开数据集和基线模型比较成熟，能够保证项目顺利推进。同时，复杂语言现象带来的误判问题又使任务本身保留了改进空间。课题后续引入困难样本增强和轻量蒸馏，正是希望在不改变任务定义的前提下，让模型在这类复杂表达上表现得更稳定。这种设计既能够回应主论文中的蒸馏思路，也能和后续的数据构造、模型比较以及结果分析自然衔接。

第4章 拟采取的技术路线与试验方案

4.1 实验数据

本课题主要采用 ChnSentiCorp 作为实验数据集，该数据集在中文情感分类研究中使用较广，样本多来自评论和用户反馈，文本长度适中，适合开展中文短文本情感分析任务。根据公开数据平台上的常见划分方式，数据集通常包含约 9.6k 条训练样本、1.2k 条验证样本和 1.2k 条测试样本，总体规模适中，能够支持基线模型训练、困难样本增强训练和蒸馏训练等后续实验。数据集可从公开平台获取，地址为 <https://huggingface.co/datasets/lansinute/ChnSentiCorp>。围绕后续实验，本课题将对原始数据进行必要的预处理，包括空样本检查、重复样本剔除、文本格式统一以及模型输入编码准备。对于 TextCNN 和 BiLSTM，可采用字级或词级表示；而对于 BERT 和 MacBERT，则使用各自的 tokenizer 完成编码。考虑到中文短文本中的标点、语气词和口语表达本身往往包含重要情绪线索，预处理阶段不会过度删除这些信息，以免削弱模型对真实表达方式的学习能力。对于后续生成的增强样本，还将额外记录原始样本编号、增强类型、标签一致性复核结果和质量信息，以便分析样本质量与模型收益之间的关系。

本课题当前不准备从零收集或创建一个完全独立的新数据集，研究主体将建立在公开中文情感分类数据之上。这一安排主要是出于课程设计时间和工作量控制的考虑。一方面，ChnSentiCorp 已能够提供较稳定的训练和测试基础；另一方面，本课题真正希望投入精力的部分并不在于重新做人为标注，而在于围绕复杂语言现象构造更有价值的训练样本。后续若需要扩充训练数据，计划采用的方式是在原始训练集基础上，调用大模型 API 生成带有否定、转折、程度变化、隐含主观表达和口语扰动等特征的困难样本，再通过标签一致性校验、重复度检查和人工抽查等步骤筛除低质量样本。经过筛选的增强样本将作为训练支持数据加入实验流程，但不作为一个完全独立的新数据集处理。这样的安排既符合课题目标，也更有利于在有限周期内完成一套可比较、可分析的实验方案。

4.2 拟使用的方法与技术

4.2.1 总体方法框架

本课题拟采用基线模型训练、困难样本增强和轻量蒸馏相结合的总体技术路线，在中文短文本情感分析任务上建立一条较完整的实验链条。整体方法框架即在已有成熟模型和公开资源的基础上，把训练重点放到复杂语言现象建模和模型鲁棒性提升上。

本课题将首先在公开中文情感分类数据集上训练 TextCNN、BiLSTM、BERT 和 MacBERT 等基线模型，形成从轻量神经网络到中文预训练模型的比较体系。在得到稳定基线后，再结合误判样本分析结果，对训练数据进行困难样本增强，并在此基础上进一步开展蒸馏训练，观察轻量模型在总体测试集和困难样本子集上的表现变化。其中，基线模型用于说明当前任务中不同模型的基本能力，困难样本增强用于补足训练数据在复杂表达上的覆盖率，蒸馏训练则用于将较强模型的知识迁移给更轻量的学生模型。经过上述框架，本课题既能完成一个完整的中文情感分析实验流程，也能够从训练策略和方法设计上体现出一定的改进性与研究性。

4.2.2 基线模型与主方法选择

本课题计划使用四类代表性模型作为主要实验对象，TextCNN、BiLSTM、BERT 和 MacBERT，以形成从轻量神经网络到中文预训练模型的性能梯度，使后续困难样本增强和蒸馏训练的效果能够在不同类型模型上得到较清楚的体现。其中，TextCNN 结构简单、训练速度快，适合观察局部 n-gram 特征对情感判断的帮助；BiLSTM 更强调上下文依赖建模，能够反映序列信息在情感分类中的作用；BERT 作为通用预训练模型，可以提供较稳定的语义表示能力；MacBERT 则作为中文强基线，适合承担高性能比较对象和后续教师模型候选角色。采用这组模型的目的，不是堆叠模型数量，而是形成层次清楚的对比体系，使后续增强训练和蒸馏训练的效果能够被更清楚地观察出来。

这四类代表性模型都将由本课题在统一数据集上重新训练和测试，由于不同研究使用的数据划分、训练轮数、参数设置和预处理方式并不完全一致，若直接使用先前发布的结果进行横向比较，结论容易受到实验条件差异影响。为保证后续增强训练和蒸馏训练的比较公平性，本课题会尽量在相同的数据预处理、相同评价指标和相近训练设定下完成基线训练。同时，已有公开结果仍会作为参考依据使用，主要用于说明该任务现有强基线的大致水平，并帮助判断本课题的实验结果是否处于合理区间。

从整体方法设计来看，这四类模型承担的角色并不完全相同。TextCNN 和 BiLSTM 更适合用来观察困难样本增强和蒸馏训练对轻量模型的帮助，其参数规模较小、训练速度较快，也更能体现轻量学生模型在接受训练支持后的提升幅度。BERT 和 MacBERT 更适合作为较强比较对象，用于观察预训练模型在原始训练、增强训练和蒸馏训练条件下的变化情况。其中，MacBERT 由于在中文任务上通常具有较强表现，故其不仅是本课题的重要比较基线，也可能在后续实验中承担教师模型角色。在主方法选择上，本课题并不准备把大模型直接作为最终情感分类器，而是将其放入训练流程内部，承担训练支持角色。大模型 API 主要用于生成候选困难样本、辅助判断增强样本的标签一致性，并为后续蒸馏训练提供教师信号，最终完成分类判断的仍然是本地训练的 TextCNN、BiLSTM、BERT 和 MacBERT 等模型。这样的设计既符合课程关于 LLM 使用方式的要求，也能使项目的重点集中在自然语言处理任务建模和实验分析上，而不是停留在简单调用接口得到结果的层面。

4.2.3 已发布方法的变体设计

本课题的方法是在已有研究思路基础上，结合中文短文本情感分析任务进行针对性调整。蒸馏部分主要借鉴 Targeted Distillation for Sentiment Analysis 中教师—学生知识迁移的基本思想，但不会复现其完整实验框架，而是把蒸馏训练与中文复杂样本建模结合起来，使方法更贴合课程设计的任务边界和实现条件。

上述变体预计主要体现在以下三个方面：

- 原论文更关注一般意义上的情感分析蒸馏，而本课题将蒸馏训练放在中文短文本情感分析场景中展开，重点关注否定、转折、程度变化、隐含主观表达和口语扰动等样本类型；
- 本课题在蒸馏训练之前增加了困难样本增强与质量控制环节，使模型不是在原始训练集上直接进入蒸馏，而是在覆盖更多复杂表达的训练集上完成后续学习；

• 本课题将大模型 API 的作用扩展到候选样本生成、标签一致性复核和样本质量控制之中，使其在训练流程里承担多重支持角色，而不仅仅是提供单一教师输出。

4.2.4 困难样本增强策略

困难样本增强是本课题最重要的方法模块之一，不是单纯简单扩大的训练数据规模，而是有针对性地提高训练数据对复杂语言现象的覆盖率。其增强对象优先从两类样本中选择：一类是基线模型容易误判的样本，另一类是本身在语义结构上具有一定复杂性的样本。围绕这些样本，本课题计划构造五类增强类型，包括否定类、转折类、程度变化类、隐含主观类和口语扰动类。每一类增强类型都对应情感分析任务中的常见误判来源，具有较明确的任务指向性。




图 4-1 困难样本数据挖掘示意图

增强样本的生成将主要通过大模型 API 完成，但候选样本不会直接加入训练集。生成后的文本需要经过一套明确的筛选流程，包括标签一致性检查、重复度检查、语义偏移检查、语言自然度检查以及必要的人工抽查。标签一致性检查用于保证改写后文本仍然保持原始情感极性；重复度检查用于避免生成句与原句过于接近，导致增强意义不足；语义偏移检查用于减少主题发生明显偏离的情况；而人工抽查则作为自动规则之外的补充质量控制手段。经过上述步骤后，最终保留下来的增强样本才会被纳入正式训练集。这样的设计能够使增强策略真正服务于模型学习，而不是只在形式上增加数据量。

4.2.5 轻量蒸馏方案

蒸馏训练部分将建立在基线实验和增强实验之后展开，本课题计划以表现较强的模型作为教师模型，为较轻量的学生模型提供更有信息量的训练信号。教师模型拟确定为 MacBERT，也可以是完成增强训练后的较强模型；学生模型则主要考虑 TextCNN、BiLSTM 或轻量化的 BERT 类模型。蒸馏训练时，学生模型既学习原始硬标签，也学习教师模型输出的软标签信息，从而获得更平滑、更稳定的类别边界。

本部分实验重点关注两个问题：

- 蒸馏训练是否能够在保持较低参数规模和较快推理速度的前提下，提高学生模型在复杂样本上的分类稳定性；
- 困难样本增强与蒸馏训练是否存在叠加收益，即增强训练带来的样本覆盖提升，是否能够进一步放大蒸馏的效果。

后续实验预计会在原始基线、仅增强、仅蒸馏以及增强加蒸馏几类设定之间进行统一比较，以保证结果具有清楚的解释空间。

4.2.6 自行实现与下载使用部分

本课题自己实现的部分主要集中在训练流程设计和方法组织层面，具体而言，即本课题将自行完成困难样本类型设计、增强模板设计、样本筛选规则设计、增强样本记录字段设计、增强训练与蒸馏训练的实验组织，以及围绕困难样本子集展开的误差分析。哪些原始样本更值得增强、不同增强类型需要满足哪些约束、候选样本如何通过一致性复核、哪些增强类型真正带来收益，这些都属于本课题将自行完成的核心工作。除此之外，本课题还预计会自行组织多组对比实验与消融实验，包括原始基线、仅增强、仅蒸馏、增强加蒸馏，以及不同增强类型和不同增强比例之间的比较。通过上述这些自实现内容，项目能够形成较完整的实验链条，也能在答辩时明确展示工作量和技術路线。

本课题亦会直接使用一部分公开资源，以保证实验效率和可实现性。公开使用的资源主要包括 ChnSentiCorp 数据集、BERT 和 MacBERT 的公开预训练权重、PyTorch 和 Transformers 等深度学习框架，以及必要的数据处理和可视化工具。这些资源的使用并不影响课题的研究性，它们承担的仅是通用基础能力，而本课题真正要完成的是在这些现有资源之上组织起适合中文短文本情感分析的训练与分析流程。具体实现中，TextCNN 和 BiLSTM 相关模型结构拟基于通用实现方式进行复现和训练，而 BERT 与 MacBERT 则采用公开模型权重进行微调。大模型 API 拟作为外部服务接入训练流程，用于生成候选增强样本和提供辅助判断信息。

4.2.7 原创内容

本课题的原创内容主要体现在方法组合和任务化落地上，围绕中文短文本情感分析任务，本课题将自行归纳和组织困难样本类型，围绕这些类型构建增强模板与筛选规则，并将增强训练和蒸馏训练放入统一实验框架中开展比较。与现有研究相比，本课题的特点在于将大模型 API 的作用明确限定在训练支持层面，通过候选样本生成、标签一致性复核和样本质量控制等环节，把 API 的贡献落实到具体方法流程中。

此外，本课题会围绕困难样本子集进行专门分析，重点观察不同模型和不同训练策略在复杂语言现象上的收益来源。此做法使本课题不只是停留在总体分数比较层面，而能够进一步回答哪些模块真正有效、哪些样本更容易带来提升、哪些增强策略可能引入噪声等问题。

4.2.8 结果评价指标

本课题将采用 Accuracy、Precision、Recall 和 Macro-F1 作为主要评价指标，用于对模型在中文短文本情感分析任务中的表现进行定量评估。Accuracy 用于反映模型在整体测试集上的分类正确率，Precision 和 Recall 用于观察模型在不同类别上的判断准确性和覆盖能力，Macro-F1 则更适合综合反映模型在整体任务中的平衡表现。由于本课题不仅关注总体测试结果，还重点关注复杂语言现象下的分类稳定性，因此除整体测试集指标外，还将额外构造并整理一个困难样本子集，对其单独统计 Accuracy 和 Macro-F1，从而更直接地观察模型在否定、转折、程度变化、隐含主观表达和口语扰动等样本上的表现变化。

为保证结果分析具有可比性，本课题会在统一的数据划分、统一的预处理方式和统一的

评价指标下，对不同实验设定进行比较。主要比较对象包括原始基线、困难样本增强训练、蒸馏训练，以及增强训练与蒸馏训练联合使用这四类设定。如时间允许，还将进一步补充不同增强类型、不同增强比例和不同教师模型条件下的消融实验。通过这种实验组织方式，可以较清楚地回答以下两个问题：

- 困难样本增强是否真正改善了模型对复杂表达的识别能力；
- 蒸馏训练是否能够在保持轻量模型可部署性的同时，进一步提升分类表现。

从已有结果来看，中文短文本情感分类任务本身已经存在较强基线。公开研究表明，在 ChnSentiCorp 这类任务上，MacBERT 等中文预训练模型能够达到较高的测试精度，这说明该任务并不是一个只要换模型就会大幅提升的问题，后续改进空间更多体现在复杂样本建模、训练样本质量和训练策略设计上。因此，本课题不会把目标简单设定为总体准确率的大幅增长，而是希望在保持总体性能稳定的基础上，使模型在困难样本子集上的表现得到更清楚、更有解释力的提升。结合课程设计的时间安排和实验条件，本课题的期望表现主要体现在两个层面。一个层面是总体测试集上达到稳定、合理的分类结果，使基线模型、增强训练和蒸馏训练之间形成清楚的性能梯度；另一层面是困难样本子集上的表现优于原始基线，能够通过定量指标和典型误判案例分析说明增强训练和蒸馏训练的实际价值。

除数值指标外，本课题还将结合典型误判样本、困难样本类别分布和不同模块收益情况进行辅助分析，使结果解释不只停留在分数提高了多少，而能够进一步说明模型具体改善了哪些问题。

第 5 章 项目实施安排

5.1 预期成果

本课题的预期成果将围绕理论研究、程序实现、数据材料和实验分析四个方面展开，力求在课程设计周期内形成较完整、可展示的研究与实现结果。

(1)**理论与方案成果**。本课题预期形成一套围绕中文短文本情感分析的完整研究思路，能够较系统地回答以下问题：为什么选择中文短文本情感分析作为任务对象，当前已有研究做到什么程度，为什么仍然需要关注困难样本与轻量蒸馏，课程设计中引入大模型 API 的合理位置是什么，以及困难样本增强与蒸馏训练怎样共同作用于模型性能提升。这部分内容将体现在开题报告和课程设计终稿中，构成整项课题的理论基础和方法主线。

(2)**程序与模型成果**。本课题预期完成一组可运行、可复现的实验程序，包括原始数据预处理脚本、TextCNN 与 BiLSTM 等轻量模型训练代码、BERT 与 MacBERT 微调代码、困难样本增强脚本、增强样本筛选与一致性复核脚本、轻量蒸馏训练代码以及实验结果统计和图表生成脚本。通过上述程序，本课题能够完成从原始数据到最终实验结果的完整流程，也便于后续答辩时展示各部分工作不是停留在概念层面，而是真正落到了可执行的实验实现上。

(3)**数据与样本成果**。本课题预期形成两类可直接用于分析的实验数据。一类是完成标准化预处理后的原始中文情感分类数据集版本，包括清洗后的训练集、验证集和测试集；另一类是基于原始训练数据生成并经过筛选的困难样本增强子集。后者将包含样本来源编号、增强类型、复核结果、质量检查记录等信息，使后续实验不仅能够使用这些样本训练模型，也能够进一步分析哪类增强策略更有效、哪类样本更容易带来收益、哪类增强可能引入噪声，这样形成的数据成果本身就具有一定研究价值。

(4)**实验与分析成果**。本课题预期得到一组具有可比性的模型结果，包括原始基线、困难样本增强训练、蒸馏训练以及增强加蒸馏联合训练在同一测试集上的性能比较。评价结果将主要通过 Accuracy、Precision、Recall 和 Macro-F1 展示，并额外设置困难样本子集指标，观察模型在复杂语言现象上的改进情况。除定量指标外，本课题还预期整理典型误判案例、困难样本类别分布以及不同模块的收益分析结果，从而能够进一步说明模型究竟改善了哪些问题。

(5)**文档与答辩成果**。在课程设计最终交付层面，本课题预期提交的成果将包括：开题报告、课程设计终稿、实验代码与运行说明、关键实验配置记录、模型结果对比表、图表材料以及答辩 PPT。若项目推进顺利，最终提交内容应为一套包含研究思路、实验实现和结果分析的完整材料。

5.2 设计进度安排

本课题预计从第六周推进到第十五周，整体按照文献准备 → 基线建立 → 问题发现 → 方法改进 → 实验验证 → 结果整理的顺序展开，项目拟推进的主线可概括为基线构建 → 误差分析 → 困难样本增强 → 知识蒸馏 → 实验分析。前期阶段主要完成选题论证、文献准备和实验基础搭建。第六周的重点是明确题目、成员分工和开题材料框架，把研究边界、

主论文依据和整体技术路线先梳理清楚。第七周继续补充文献阅读，完善研究现状、最相关论文总结以及课题目标与论文之间的关系说明。到这一阶段结束时，课题应当已经形成一版较完整的开题报告，并能够较清楚地说明为什么选择当前主论文、为什么采用当前任务、为什么引入困难样本增强和轻量蒸馏。

中期阶段转入数据准备和基线构建。第八周主要完成 ChnSentiCorp 的下载、清洗、划分和输入格式整理，同时搭建统一实验环境和基础训练框架。第九周到第十周集中训练 TextCNN、BiLSTM、BERT 和 MacBERT 等基线模型，并整理典型误判样本。此阶段争取先得到一组可靠、可复现的基线结果，并在此基础上判断哪些模型更强、哪些样本更容易误判。只有基线足够清楚，后续方法改进才有比较依据。

后期阶段主要围绕方法改进和结果分析展开。第十一周将在误差分析基础上设计困难样本增强方案，围绕否定、转折、程度变化、隐含主观表达和口语扰动等现象生成候选样本。第十二周用于候选样本筛选、标签一致性复核和人工抽查，形成正式增强训练集。第十三周开展增强训练和蒸馏训练实验，对原始基线、仅增强、仅蒸馏以及增强加蒸馏几类设定进行统一比较。第十四周集中整理实验结果，完成图表绘制、典型误判案例分析和必要的消融实验补充。第十五周用于课程设计终稿、代码整理和答辩材料准备。直观阶段重点与产出如表 5-1 所示。

表 5-1 设计进度安排

周次	工作重点	阶段产出
第 6-7 周	选题、分工、文献与开题	开题报告初稿
第 8 周	数据清洗与环境搭建	可训练数据版本
第 9-10 周	基线训练与误差分析	基线结果、误判样本
第 11 周	增强方案设计	增强类型与模板
第 12 周	样本筛选与复核	增强训练集
第 13 周	增强与蒸馏实验	主要对比结果
第 14 周	图表整理与分析	图表、案例分析
第 15 周	终稿与答辩准备	终稿、代码、PPT

5.3 小组成员和分工

本课题的小组分工以前期统稿集中负责，后续任务协同推进为原则进行安排。考虑到开题阶段需要较快形成统一思路和完整文本，因此开题报告的主体撰写、结构统筹和前期资料整合主要由一名成员负责完成，以保证报告整体逻辑一致、表述风格统一。进入实验实施阶段后，数据处理、模型训练、困难样本增强、蒸馏实验、结果分析和终稿整理等工作再由四名成员共同分担，避免出现前期有人过重、后期有人过轻的情况。这样的安排既符合项目推

进的实际需要，也有利于提高整体协作效率。具体小组分工如表 5-2 所示。

表 5-2 小组成员分工

成员	分工
许以诺	开题报告的主体撰写、主论文与辅助文献整理、结构设计、TextCNN、BiLSTM 等基线模型训练与调参，对接大模型 API，参与困难样本生成、增强训练和蒸馏训练
陈康	主论文与辅助文献整理、开题材料统稿与修改，整体结构设计、负责数据预处理及增强样本来源信息和筛选记录整理；后续参与困难样本构造与数据质量检查
侯睿元	主论文与辅助文献整理、开题报告图表绘制，BERT、MacBERT 等基线模型训练与调参，对接大模型 API，参与困难样本生成、增强训练和蒸馏训练
谭逸朗	辅助文献整理，实验结果统计、图表绘制、典型误判案例整理、消融实验辅助分析、报告排版和答辩 PPT 制作，后续结果分析和终稿整合